

Redes Convolucionales

1. Entrenar y evaluar la performance de una red convolucional que aprende a clasificar la base de datos MNIST. Primero utilizaremos Keras (v3) con tensorflow como backend
 - Bajar la base de datos usando `keras.datasets.mnist.load_data()`
 - Examinar visualmente los imágenes (x) y compararlas con las clasificaciones (y)
 - Rescalar los datos entre 0 y 1
 - Definir la dimensión de entrada y el número de clases
 - Crear un modelo con la sintaxis secuencial usando *keras.Sequential*
 - Agregar capas alternando capas Conv2D y MaxPooling. terminar con GlobalAveragePooling2D y una capa dense
 - Imprimir el modelo con `model.summary()`
 - Compilar el modelo definiendo la pérdida (CategoricalCrossEntropy), el optimizador (Adam) y la métrica (acc)
 - Definir el número de épocas y el batchsize
 - entrenar el modelo con `model.fit`
 - Calcular los scores con sobre el conjunto de test con `model.evaluate`
2. Ahora repetamos el ejercicio usando pytorch
 - Crear la clase NN que hereda los atributos de `torch.nn`
 - En `__init__` definir las capas combinando Conv2D y Linear
 - En forward definir la propagación combinando relu con max_pool2d y finalmente xview para poner la matriz en un vector. La salida final se obtiene aplicando log_softmax.
 - Comparar esta sintaxis con la de keras, especialmente el cálculo de dimensiones
 - Definir el batch size, número de clases, learning rate y número de épocas.

- Cargar los datos con `torchvision.datasets.MNIST` y crear el dataloader
- Instanciar el modelo, definir la función de pérdida y el optimizador.
- Implementar el proceso de aprendizaje con un loop sobre épocas y un loop sobre batches anidados
- En cada paso realizar
 - La propagación para delante
 - El cálculo de la pérdida
 - Poner los gradientes a 0
 - Cálculo de los gradientes
 - Llamar al optimizador
 - acumular la pérdida
- Calcular las predicciones sobre los datos de test item Opcionalmente calcular la matriz de confusión usando `confusion_matrix` y `ConfusionMatrixDisplay` de `sklearn.metrics`

3. Entrenar y evaluar la performance de una red con arquitectura U-net que realiza una tarea de segmentación semántica

- Descargar el directorio `oxford-iiit-pet` del repositorio. Las imágenes se encuentran en el subdirectorio `images/` y los targets en el subdirectorio `annotations/trimaps/`. Examinar un ejemplo.
- Crear una función que carga las imágenes por batch haciendo un `resizing` a tamaño adecuado. Se pueden usar las funciones `tf.io.read_file`, `tf.io.decode_png`, `tf.image.resize`, `tf.image.convert_image_dtype`.
- Crear la arquitectura `unet` usando la sintaxis funcional. Crear un path de bloques convolucionales cada vez mas chicos pero con mas canales, guardando las salidas adecuadas para ser concatenadas en el camino de `upsampling` en la posición adecuada. Calcular las dimensiones en cada paso del proceso.
- Entrenar el modelo usando `sparse_categorical_crossentropy` como pérdida.
- Examinar la performance sobre los datos de validación
- Optimizar la arquitectura.