

## Modelos de Difusión

1. Proceso *directo*: considerar un proceso iterativo con condición inicial  $\mathbf{x}_0$  y que en cada paso de tiempo evoluciona de acuerdo a

$$\mathbf{x}_t = \sqrt{1 - \beta_t} \mathbf{x}_{t-1} + \sqrt{\beta_t} \epsilon_t \quad (1)$$

donde  $\epsilon_t$  es una variable gaussiana con media 0 y varianza 1 independiente para cada tiempo y  $\beta_t$  son coeficientes positivos y menores que 1.

- ¿Cuál es la distribución de probabilidad de  $\mathbf{x}_t$  para  $t > 0$ ?
- Demostrar que su media es  $\sqrt{\tilde{\alpha}_t} \mathbf{x}_0$  y su matriz de covarianza es  $(1 - \tilde{\alpha}_t)I$  para todo  $t$  donde  $\tilde{\alpha}_t = \prod_{t' \leq t} \alpha_{t'}$  y  $\alpha_t = 1 - \beta_t$

2. Proceso *inverso*: definimos el proceso inverso por la relación de recursividad

$$\mathbf{x}_{t-1} = \mu(\mathbf{x}_t) + \sqrt{\beta_t} \epsilon_t \quad (2)$$

donde la función  $\mu(\mathbf{x})$  denota la media del proceso inverso.

Este proceso también se puede pensar condicionado a  $\mathbf{x}_0$ :

$$\mathbf{x}_{t-1} = \mu(\mathbf{x}_t, \mathbf{x}_0) + \sqrt{\beta_t} \epsilon_t \quad (3)$$

Esta relación define  $p(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)$

- Utilizando la regla de Bayes calcular esta cantidad en término de  $p(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{x}_0)$ ,  $p(\mathbf{x}_t | \mathbf{x}_0)$  y  $p(\mathbf{x}_{t-1} | \mathbf{x}_0)$
- Usando las probabilidades del proceso directo para estas tres probabilidades demostrar que la media del proceso inverso condicionado es

$$\mu(\mathbf{x}_t, \mathbf{x}_0) = \frac{\sqrt{\alpha_t}(1 - \tilde{\alpha}_{t-1})}{1 - \tilde{\alpha}_t} \mathbf{x}_t + \frac{\sqrt{\tilde{\alpha}_{t-1}}\beta_t}{1 - \tilde{\alpha}_t} \mathbf{x}_0 \quad (4)$$

- Usando que el proceso directo se puede escribir como

$$\mathbf{x}_t = \sqrt{\tilde{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \tilde{\alpha}_t} \epsilon_t \quad (5)$$

eliminar  $\mathbf{x}_0$  y probar que la media del proceso inverso se puede escribir como

$$\mu(\mathbf{x}_t) = \frac{1}{\sqrt{\alpha_t}} \left( \mathbf{x}_t - \frac{\beta_t}{\sqrt{1 - \tilde{\alpha}_t}} \epsilon_t \right) \quad (6)$$

- Este resultado motiva la propuesta de

$$\mu_\theta(\mathbf{x}_t) = \frac{1}{\sqrt{\alpha_t}} \left( \mathbf{x}_t - \frac{\beta_t}{\sqrt{1 - \tilde{\alpha}_t}} \epsilon_\theta(\mathbf{x}_t) \right) \quad (7)$$

donde  $\epsilon_\theta(\mathbf{x}_t)$  es una función implementada con una red neuronal para “aprender” la variable aleatoria necesaria para invertir la inyección de ruido. Observar que el sistema requiere conocer el tiempo  $t$ , así que si queremos usar una sola red neuronal debemos embeber esa variable en la entrada de la red:  $\epsilon_\theta(\mathbf{x}_t) \rightarrow \epsilon_\theta(\mathbf{x}, t)$

3. Bajar la imagen de referencia del condor del repositorio e implementar el proceso directo con un valor fijo de que cambia linealmente en tiempo desde  $\beta_0 = 0.0001$  hasta  $\beta_T = 0.02$ , con  $T = 200$ . Examinar la degradación a medida que se agraga ruido. Graficar  $\mathbf{x}_0$ ,  $\mathbf{x}_3$ ,  $\mathbf{x}_{10}$ ,  $\mathbf{x}_{30}$ ,  $\mathbf{x}_{100}$ ,  $\mathbf{x}_{200}$ .
4. Programar una red neuronal con arquitectura Unet que incluya el tiempo embebido como entrada adicional. Definir una clase TimeEmbedding(nn.Module).
5. Escribir una función de pérdida muestreando el intervalo de tiempos  $[0, T]$  de manera uniforme y definiendo

$$L = \|\epsilon - \epsilon_\theta(\mathbf{x}_t(\mathbf{x}_0, \epsilon), t)\|^2 \quad (8)$$

donde  $\epsilon$  es una variable gaussiana con media 0 y varianza 1 y  $\mathbf{x}_t(\mathbf{x}_0, \epsilon)$  está generado por el proceso directo.

6. Entrenar la red usando los datos de mnist y evaluar su performance en términos de la capacidad de eliminar el ruido de una muestra que pasó por el proceso directo.